

```
In [1]: import numpy as np
import matplotlib.pyplot as plt
import itertools
```

A

```
In [2]: def is_in_hipersphere(point,radius,center_point):
return np.square(point - center_point).sum() <= np.square(radius)
```


```
In [3]: def generate_random_point(min_val,max_val,dim):
np.random.rand(dim)
return np.random.rand(dim)*(max_val-min_val) - abs(min_val)
```

```
In [4]: X = 1
def space(dim,density):
return np.array([generate_random_point(-X,X,dim) for _ in np.arange(density)])
```

```
In [5]: density= 10000
dims = np.arange(1,20)
aggr_counts=[]
counts = []

for _ in range(10):
    for dim in dims:
        spc = space(dim,density)
        mask = np.array([is_in_hipersphere(point,X,np.zeros(dim)) for point
in spc])
        counts += [len(spc[mask])/density*100]
        aggr_counts += [np.array(counts)]
        counts = []
```

```
In [6]: mean_counts = np.mean(aggr_counts,axis=0)
deviation= np.std(aggr_counts,axis=0)
fig,ax = plt.subplots(figsize=(10,10))
ax.errorbar(dims,mean_counts,yerr=deviation)
plt.xlim(1,20)
ax.set_xlabel('Dimension')
ax.set_ylabel('% of points inside the hipersphere')
plt.show()
```




Można zauważyć że wraz ze wzrostem wymiaru przestrzeni spada objętość hiperkuli względem objętości sześcianu, co jest zjawiskiem oczekiwanym

B

```
In [7]: def space(density,dim):
return np.array([generate_random_point(0,1,dim) for _ in np.arange(density)])
```

```
In [8]: dims = np.arange(2,20,2)
coeff = []
for dim in dims:
    tmp_coeff = []
    for _ in range(10):
        spc = space(1000,dim)
        combs = np.array(list(itertools.combinations(spc,2)))
        distances = np.sqrt(np.sum(np.sum(np.square(combs),axis=2),axis=1))
        tmp_coeff += [np.std(distances)/np.mean(distances)]
    coeff += [np.mean(tmp_coeff)]
    tmp_coeff = []
```

```
In [9]: fig,ax = plt.subplots(figsize=(10,10))
ax.scatter(dims,coeff)
ax.set_xlabel('Dimension')
ax.set_ylabel('Variation')
plt.show()
```



Widzimy że spada wariancja odległości dwóch losowo wybranych punktów, wynika to z tego że odległość punktów zależy od położenia a to zależy od losowo wybranych punktów. Zatem zwiększając poziom wymiaru, upodabniamy punkty względem odległości => odległość jest słabą metryką różnicującą w przestrzeni hiperwymiarowej.

C


```
In [10]: def unit_vector(vector):
        return vector / np.linalg.norm(vector)

        def angle_between(v1, v2):
            v1_u = unit_vector(v1)
            v2_u = unit_vector(v2)
            return np.arccos(np.clip(np.dot(v1_u, v2_u), -1.0, 1.0))
```


```
In [11]: def show_histogram(spc):
        size = spc.shape[0]
        shuffled = np.random.permutation(spc)
        shuffled_pairs = [angle_between(*i) for i in zip(shuffled[:size-1], shuffled[1:size])]
        fig, ax = plt.subplots(figsize=(10,10))
        ax.hist(shuffled_pairs)
        ax.set_xlabel('Degree')
        ax.set_ylabel('Number of occurrences')
        plt.xlim(-.5, 3.15)
        print(f'Current dim {dim}')
        plt.show()
```

```
In [12]: for dim in range(2,100,10):  
         spc = space(2*1000,dim)  
         show_histogram(spc)
```


Current dim 2




Current dim 12




Current dim 22




Current dim 32




Current dim 42




Current dim 52




Current dim 62




Current dim 72



Current dim 82



Current dim 92



Widzimy że miara kąta losowo stworzonego wektora dąży do ok 40 stopni co pokazuje że miara tego kąta również nie będzie dobrym rozróżnikiem przy identyfikacji wektorów w przestrzeniach wielo wymiarowych.